

CredScore AI: Decifrando o Risco de Crédito

Rodrigo Daiske Uehara¹, [Nome do(a) colega]¹

¹Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie
(MACK)

São Paulo, SP – Brasil

daiskeuehara20@hotmail.com, 10440295@mackenzista.com.br

Resumo. Este projeto compara Regressão Logística, Random Forest e XGBoost para prever o risco de inadimplência de clientes de crédito ao consumidor, usando o dataset público Statlog (German Credit Data). A meta é um sistema de credit scoring preciso e transparente, alinhado à inclusão financeira e aos ODS 8 e 10. Nesta etapa, fizemos a análise exploratória dos dados e definimos o protocolo experimental, com tratamento do desbalanceamento e uso de SHAP (XAI). Espera-se diminuir bem os erros nas decisões de crédito, avaliando desempenho e equidade entre grupos.

1. Introdução

1.1. Contextualização

A concessão de crédito é importante para bancos, mas arriscada: emprestar para quem não paga gera prejuízo, e negar para quem pagaria certinho tira receita do banco e prejudica o cliente. Trabalhamos com crédito ao consumidor (pessoa física, não empresarial), usando o dataset público Statlog (German Credit Data) [Hofmann 1994], de um banco alemão não identificado por confidencialidade — o público-alvo são clientes que pedem crédito ao consumidor nesse banco.

A base já vem com o rótulo pronto (bom ou mau pagador), mas não detalha quantos dias de atraso definem a inadimplência. Assumimos esse rótulo como está fornecido, o que é uma simplificação: com dados próprios de uma empresa, o ideal seria definir esse horizonte de forma explícita (por exemplo, 90 dias de atraso).

1.2. Justificativa

A proposta é fazer um sistema de credit scoring preciso e transparente, que ajude na inclusão financeira e avalie o risco de crédito de forma mais justa, evitando dois erros: conceder crédito a quem não vai pagar (inadimplência) e negar indevidamente a quem pagaria certinho (o que prejudica o cliente e tira receita do banco).

No parecer da primeira entrega, o professor corrigiu que não é evitar conceder crédito a bons pagadores que buscamos — é o contrário: evitar negar crédito indevidamente a eles. Já ajustamos esse trecho. Também reforçamos que inclusão financeira e redução da discriminação não são automáticas só por usar IA: precisam ser testadas comparando desempenho e equidade entre grupos (sexo, faixa etária), não presumidas como consequência do projeto.

1.3. Motivação

A inadimplência encarece o crédito para todo mundo, já que os juros sobem quando o risco de calote é maior. Um modelo mais preciso e transparente pode ajudar a diminuir bem esse problema e tornar o crédito mais acessível para quem realmente vai pagar — tema relevante no Brasil, onde o acesso ao crédito ainda é desigual e a inadimplência das famílias é recorrente.

O projeto está alinhado a dois ODS da ONU, os mesmos da proposta inicial: ODS 8 – Trabalho Decente e Crescimento Econômico, porque um crédito mais justo movimenta a economia sem prejudicar quem já tem dificuldade de acesso; e ODS 10 – Redução das Desigualdades, porque a intenção é diminuir a diferença no acesso ao crédito entre grupos, e não deixá-la maior.

1.4. Objetivo

O objetivo é comparar modelos de aprendizado de máquina supervisionado para prever se um cliente vai pagar o crédito, construindo um sistema preciso e fácil de explicar. Queremos diminuir bem a taxa de erro nessas decisões — tanto liberar crédito para quem não vai pagar quanto negar indevidamente para quem pagaria certinho — contribuindo para a inclusão financeira e para os ODS 8 e 10 da motivação. A variável-alvo é a coluna Risk, transformada em binária: 1 para mau pagador (inadimplente) e 0 para bom pagador (adimplente), com foco em identificar a classe “mau pagador”.

Comparamos três modelos — Regressão Logística (mais simples e interpretável), Random Forest e XGBoost (mais complexos) — com métricas próprias para dados desbalanceados: F1-score, recall da classe inadimplente, PR-AUC, matriz de confusão e calibração, e não só a acurácia, que engana em bases como esta.

No melhor modelo, aplicaremos SHAP (XAI) para explicar as decisões e métricas de equidade entre sexo e faixa etária, verificando na prática se caminhamos rumo à inclusão financeira e não só supondo isso. Esperamos um F1-score e recall melhores que um baseline simples, com diferença de desempenho entre grupos dentro de limites razoáveis.

1.5. Contribuições esperadas

- Formalizar a inadimplência como uma tarefa de classificação supervisionada, com variável-alvo, protocolo e métricas bem definidos.
- Limpar, tratar valores ausentes e balancear as classes da base, de forma justificada.
- Desenvolver e comparar Regressão Logística, Random Forest e XGBoost.
- Demonstrar quantitativamente vantagens e limitações de cada modelo com métricas apropriadas.

- Aplicar SHAP (XAI) para identificar as variáveis que mais influenciam a previsão.
- Discutir criticamente vieses, riscos éticos e diferenças de desempenho entre grupos de clientes.

2. Fundamentação Teórica (Resumida)

2.1. Conceitos fundamentais

Usamos aprendizado supervisionado: o modelo aprende com exemplos já rotulados (bom/mau pagador) para prever o rótulo de clientes novos, num problema de classificação binária. Comparamos Regressão Logística (simples e interpretável), Random Forest (várias árvores combinadas) e XGBoost (árvores em sequência, cada uma corrigindo a anterior, com ótimo desempenho em dados tabulares como o nosso).

Como o dataset é desbalanceado, ajustaremos o peso das classes no treino (`class_weight`) e testaremos o SMOTE, que cria exemplos sintéticos da classe minoritária [Chawla et al. 2002]. Também usaremos XAI via SHAP [Lundberg e Lee 2017], que explica a contribuição de cada variável nas decisões — essencial num setor regulado como o financeiro.

2.2. Trabalhos relacionados

Gramegna e Giudici (2021) mostraram que o SHAP tem poder discriminativo maior que o LIME em risco de crédito (AUC 0,864 x 0,839), reforçando nossa escolha do SHAP [Gramegna e Giudici 2021]. De Lange et al. (2022) discutem como o XAI ajuda bancos a cumprir exigências regulatórias de transparência [de Lange et al. 2022]. Para o desbalanceamento, usamos como referência Chawla et al. (2002), que propôs o SMOTE [Chawla et al. 2002]. Não encontramos um trabalho com exatamente essa combinação de modelos, dataset e avaliação de equidade, o que reforça a relevância do nosso recorte.

3. Metodologia e Resultados Esperados

3.1. Abordagem, etapas e resultados esperados

As etapas são: (1) EDA e preparação dos dados — já feita e detalhada na Seção 3.2; (2) treino dos três modelos com validação cruzada estratificada; (3) avaliação no conjunto de teste com F1-score, recall da classe inadimplente, PR-AUC, matriz de confusão e calibração; (4) SHAP no melhor modelo; (5) avaliação de equidade entre sexo e faixa etária; (6) discussão crítica dos resultados, limitações e riscos éticos.

Esperamos que XGBoost ou Random Forest superem a Regressão Logística em F1-score e recall, com esta servindo de referência mais interpretável, mostrando o trade-off entre desempenho e interpretabilidade. O treino e a comparação dos modelos ficam para a N2.

3.2. Dataset, análise exploratória e preparação dos dados

O dataset é o Statlog (German Credit Data) [Hofmann 1994], do UCI Machine Learning Repository, licenciado CC BY 4.0. Usamos a versão simplificada (9 variáveis preditoras + a variável-alvo Risk, em vez das 20 da versão completa, comum no Kaggle), com 1.000 registros anonimizados e de acesso público — a base recomendada pelo professor.

A EDA completa está no notebook 01_analise_exploratoria.ipynb, no GitHub (Seção 4.3). Principais achados:

- alvo desbalanceado: 700 bons pagadores (70%) e 300 maus pagadores (30%);
- Saving accounts e Checking account têm 18,3% e 39,4% de ausentes, que parecem significar “sem conta”: quando Checking account está ausente, a taxa de mau pagador cai para 11,7% (contra 41,9% quando presente);
- mulheres têm taxa de mau pagador maior que homens (35,2% x 27,7%), e clientes de 18–25 anos maior que os de 60+ (42,1% x 22,2%) — diferenças a acompanhar na avaliação de equidade;
- maus pagadores pedem, em média, valores e prazos maiores (3.938 marcos/24,9 meses) que bons pagadores (2.985 marcos/19,2 meses).

Plano de preparação: tratar os ausentes como categoria “sem conta”, codificar as categorias (one-hot/ordinal), padronizar as numéricas e separar treino/teste (70/30) estratificado — pipeline já implementado e testado no notebook, sem vazamento de dados.

4. Resultados Parciais

4.1. Aspectos éticos e responsabilidade no uso da IA

Os dados usados — idade, sexo, situação financeira, histórico de crédito — são pessoais e, num cenário real, sustentariam decisões de alto impacto. Mesmo com um dataset público e anonimizado (o que dispensa CEP, segundo o professor), consideramos os princípios da LGPD [Brasil 2018] que valeriam para um sistema real: finalidade, minimização, segurança, transparência e o direito à revisão de decisões automatizadas (art. 20).

Como o professor destacou, explicabilidade não garante ausência de discriminação: só porque explicamos a decisão do modelo (via SHAP) não significa que ele seja justo entre grupos. Por isso desempenho e equidade serão avaliados separadamente, entre sexo e faixa etária, sem presumir que a explicabilidade sozinha resolve isso. Também não usaríamos dados reais de uma instituição sem autorização formal e avaliação prévia dos riscos — por isso o dataset público recomendado.

4.2. Detalhamento dos resultados parciais obtidos até o momento

Até agora: (1) dataset definido — Statlog (German Credit Data) [Hofmann 1994], recomendado pelo professor; (2) EDA completa, com o desbalanceamento (70/30) e o achado sobre os ausentes; (3) análise descritiva por sexo e faixa etária, base para a

futura avaliação de equidade; (4) protocolo experimental definido (alvo binário, split estratificado 70/30, validação cruzada, class_weight/SMOTE, e as métricas F1-score, recall, PR-AUC, matriz de confusão, calibração e equidade); (5) pipeline de pré-processamento implementado e testado no notebook. O treino dos modelos e o SHAP ficam para a N2.

4.3. Endereço GitHub

Repositório público: <https://github.com/DADAISKE/Projeto-IA> . Nele: o artigo, o dataset com breve descrição, e o notebook 01_analise_exploratoria.ipynb com a EDA e seus resultados, com cabeçalho de identificação, síntese e histórico de atualizações.

5. Referências

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, DF, 2018.

CHAWLA, N. V.; BOWYER, K. W.; HALL, L. O.; KEGELMEYER, W. P. (2002) “SMOTE: Synthetic Minority Over-sampling Technique”, Journal of Artificial Intelligence Research, v. 16, p. 321-357.

DE LANGE, P. E.; MELSOM, B.; VENNERØD, C. B.; WESTGAARD, S. (2022) “Explainable AI for Credit Assessment in Banks”, Journal of Risk and Financial Management, v. 15, n. 12, artigo 556.

GRAMEGNA, A.; GIUDICI, P. (2021) “SHAP and LIME: An Evaluation of Discriminative Power in Credit Risk”, Frontiers in Artificial Intelligence, v. 4, artigo 752558.

HOFMANN, H. (1994) “Statlog (German Credit Data)”, UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data>.

LUNDBERG, S. M.; LEE, S.-I. (2017) “A Unified Approach to Interpreting Model Predictions”, Advances in Neural Information Processing Systems (NeurIPS), v. 30.